

RAPPORT DE STAGE DE FIN DE MASTER 1

Département Sciences de l'ingénieur

Master Automatique - Robotique, parcours Systèmes Intelligents

Exploitation de la dynamique temporelle des réseaux de neurones à spikes pour la reconnaissance d'activités

Établissements	Sorbonne Université / CY Cergy Paris Université
Laboratoire d'accueil	ETIS - Équipe Neurocybernétique
Encadrants	Mathias Quoy et Camille Simon-Chane
Réalisé par	Abderraouf Tarek Kessouar
Année universitaire	2025 - 2026

Résumé

Une caméra événementielle ne transmet pas des images, mais uniquement les changements de luminosité, pixel par pixel et à mesure qu'ils surviennent. Ce mode d'acquisition, économe et très précis dans le temps, intéresse la surveillance d'activités à domicile : il permettrait de détecter une chute sans jamais enregistrer d'image sur laquelle une personne serait reconnaissable. Les réseaux de neurones impulsionnels, dont chaque unité conserve une trace de ce qu'elle vient de recevoir, sont réputés les mieux adaptés à ces données. Ce stage examine si cette mémoire interne est réellement mise à profit.

Le vérifier suppose une tâche dont la solution dépende de l'ordre des événements. Trois activités sont donc mises bout à bout, et c'est leur ordre qui définit la classe à reconnaître : marcher, s'asseoir puis chuter n'est pas la même classe que chuter, marcher puis s'asseoir. Un réseau sans mémoire peut identifier quelles activités sont présentes, mais pas les ordonner ; on montre qu'il ne peut pas dépasser 37 % de bonnes réponses, contre 3,7 % en répondant au hasard.

Sur des activités quotidiennes enregistrées auprès de cent personnes, et en évaluant les modèles sur des participants qu'ils n'ont jamais vus, le réseau sans mémoire atteint 32 %, soit exactement sa limite théorique, tandis que le réseau impulsional atteint 97 %. Les deux ne différant que par leur neurone, à architecture, données et normalisation identiques, l'écart est imputable à cette seule mémoire.

Obtenir cette mesure a demandé de corriger d'abord le dispositif chargé de la produire. Sur un premier banc d'essai, un détail du réglage interne du réseau communiquait discrètement la position de chaque activité dans la séquence : un modèle dépourvu de toute mémoire y atteignait 99 %. Mettre au jour cette fuite, puis construire un point de comparaison réellement aveugle à l'ordre, était la condition pour que l'écart mesuré signifie quelque chose ; c'est le principal apport méthodologique de ce travail. Un réseau récurrent conventionnel résout par ailleurs la tâche aussi bien que le réseau impulsional : la difficulté ne tient donc pas à la tâche elle-même, ce qui confirme que l'échec des modèles sans mémoire vient bien de l'absence de dynamique temporelle. Le protocole et le contrôle mis au point ici ne dépendent ni du jeu de données ni de l'architecture, et se transposent à toute étude cherchant à établir ce qu'un mécanisme temporel apporte réellement.

Table des matières

Résumé	2
Glossaire et sigles	4
1 Introduction	5
1.1 Organisme d'accueil et objectifs	5
1.2 Contexte du stage	5
1.3 Démarche et organisation du rapport	6
2 Cadre scientifique	7
2.1 Nature des données événementielles	7
2.2 Familles de modèles pour le traitement temporel	7
2.3 Le neurone impulsionnel	8
2.4 Entraînement des réseaux impulsionnels	8
2.5 Positionnement par rapport aux travaux existants	9
2.6 Règles d'évaluation	9
3 Perception de l'ordre temporel	10
3.1 Le jeu de données et sa préparation	10
3.2 Le protocole de chaînage	10
3.3 Dispositif expérimental	11
3.4 Reproduction du protocole de référence	12
3.5 Effet du recouvrement spatial et de la résolution temporelle	12
3.6 Rôle du mécanisme temporel	12
3.7 Bilan de la campagne DVS-GC	13
4 Reconnaissance d'activités sur MAD	14
4.1 Le jeu de données et sa préparation	14
4.2 Le protocole MAD-Chain	15
4.3 Dispositif expérimental	15
4.4 Diagnostic de l'instabilité en validation	15
4.5 Normalisation conjointe	16

4.6	Robustesse du protocole	17
4.7	Bilan de la campagne MAD	17
5	Étude préliminaire de la détection de chute	18
5.1	Le protocole de détection	18
5.2	Dispositif expérimental	18
5.3	Pondération de la classe rare et point de fonctionnement	19
5.4	Bilan de l'étude	20
6	Synthèse et conclusion	21
6.1	Réponse à la problématique	21
6.2	Bilan du travail réalisé	21
6.3	Apports méthodologiques	22
6.4	Compétences mobilisées et acquises	22
6.5	Perspectives	23
	Bibliographie	24
	Annexes	26
A	Hyperparamètres et effectifs	26
B	Analyses complémentaires	28
C	Infrastructure expérimentale	30
D	Un travail exploratoire : estimation du flot optique	33

Glossaire et sigles

ANN	Réseau de neurones artificiels	DSEC	Données stéréo événementielles de conduite
BN	Normalisation par lot	DVS	Capteur dynamique de vision événementielle
BNTT	Normalisation par lot propre à chaque instant	DVS-GC	Chaînes ordonnées issues de DVS-Gesture
F1	Moyenne harmonique précision-rappel	GPU	Processeur graphique de calcul parallèle
GRU	Unité récurrente à portes	HDF5	Format hiérarchique de stockage de données
IF	Neurone à intégration et décharge, sans fuite	LIF	Neurone à intégration et décharge avec fuite
LSTM	Réseau récurrent à mémoire longue durée	MAD	<i>Multimodal Activity Dataset</i>
ReLU	Unité linéaire rectifiée	SNN	Réseau de neurones impulsionnels
S-ResNet-38	Réseau résiduel impulsif de 38 couches	tdBN	Normalisation par lot commune aux instants

Introduction

L'ingénierie neuromorphique part du constat que le système nerveux traite l'information visuelle avec une grande efficacité, grâce à un calcul local, asynchrone et déclenché par le changement plutôt que cadencé par une horloge. Elle ne cherche pas à reproduire le vivant dans le détail, mais à en reprendre certains principes de fonctionnement. Ce stage réunit les deux versants issus de cette démarche : la caméra événementielle pour l'acquisition et les réseaux de neurones à spikes (*Spiking Neural Networks*, SNN) pour le traitement. Tous deux ne produisent un signal que lorsqu'un événement survient. Le rapport examine si cette parenté de principe se traduit effectivement par une exploitation de la dynamique temporelle, plutôt que par un simple avantage de représentation ou d'architecture.

1.1 Organisme d'accueil et objectifs

Le stage s'est déroulé du 19 mai au 19 août 2026 au laboratoire ETIS (UMR 8051, CNRS, ENSEA et CY Cergy Paris Université), sous l'encadrement de Monsieur Mathias Quoy et Madame Camille Simon-Chane, dans l'équipe Neurocybernétique consacrée à l'incarnation et à la bio-inspiration des systèmes cognitifs.

L'objectif était de déterminer si un réseau impulsionnel exploite réellement sa dynamique interne pour traiter des données événementielles. Deux campagnes complémentaires ont porté sur la reconnaissance d'activités : des gestes de bras dans un cadre contrôlé, puis des activités du corps entier enregistrées auprès d'une centaine de participants, avec des personnes distinctes pour l'apprentissage et l'évaluation. Une étude plus courte a prolongé ce protocole vers la détection de chute. Une prise en main préalable du flot optique événementiel est rapportée en [Annexe D](#).

1.2 Contexte du stage

Un besoin applicatif : surveiller sans filmer

La chute à domicile constitue un enjeu de santé : en France, 174 824 hospitalisations liées à une chute ont concerné les plus de 65 ans en 2024 ([Santé publique France, 2026](#)), et sa gravité dépend fortement du délai avant les secours ([Wang et al., 2020](#)). Une détection automatique pourrait réduire ce délai sans imposer le port permanent d'un dispositif.

Une caméra conventionnelle soulève toutefois une difficulté immédiate : elle produit des images identifiables dans des lieux privés. Le capteur événementiel ne transmet que des variations locales de luminosité, sans texture ni couleur. La silhouette et le mouvement restent donc exploitables alors que le visage ne l'est pas, avec en outre une faible consommation et une haute résolution temporelle. C'est dans cette perspective qu'ETIS a constitué MAD, jeu multimodal d'activités quotidiennes, dont la chute, qui soutient la seconde campagne et l'étude du [Chapitre 5](#).

Un choix de capteur

Une caméra conventionnelle produit des images complètes à intervalles réguliers, même lorsque la scène ne change pas. Une caméra événementielle fait fonctionner chaque pixel indépendamment : toute variation locale de luminosité génère un événement (x, y, t, p) . Ce flux asynchrone concentre ainsi la représentation

sur le mouvement et le situe avec une grande précision temporelle (Gallego et al., 2022). La Figure 1 compare les deux acquisitions.




FIGURE 1 : Principes d'acquisition comparés : une caméra conventionnelle fournit des images complètes, tandis qu'une caméra événementielle signale les changements de luminosité pixel par pixel.

Source : *Shidling*

Problématique

La dynamique interne justifie habituellement le choix d'un SNN, mais les protocoles usuels peuvent souvent être résolus par l'apparence globale d'une séquence. Ils ne prouvent donc pas que le réseau exploite sa chronologie. La question étudiée est la suivante :

La dynamique temporelle interne d'un réseau de neurones impulsionnels est-elle effectivement exploitée pour percevoir l'ordre d'activités décrites par un flux événementiel, et cet apport se maintient-il lorsque l'on passe de gestes contrôlés à des activités réelles observées sur des personnes que le modèle n'a jamais vues ?

Y répondre exige une tâche dépendant nécessairement de l'ordre, un contrôle sans mémoire et une évaluation sur des personnes absentes de l'apprentissage.

1.3 Démarche et organisation du rapport

La même démarche a été appliquée à chaque étape : lecture critique de l'article de référence, analyse du code disponible, réimplémentation du prétraitement et du modèle, entraînement sur les serveurs GPU, sauvegarde des checkpoints, visualisation des données et analyse des erreurs. La réimplémentation, plutôt qu'une simple exécution, a notamment permis de modifier en profondeur la stratégie de normalisation.

Le rapport suit l'ordre dans lequel les conditions d'une comparaison interprétable ont été réunies : le cadre scientifique et les règles d'évaluation (Chapitre 2), le dispositif contrôlé de DVS-GC (Chapitre 3), sa transposition à MAD avec séparation stricte par participant (Chapitre 4), puis son prolongement vers la détection d'un événement critique (Chapitre 5).

Cadre scientifique

2.1 Nature des données événementielles

Un événement est décrit par

$$e_i = (x_i, y_i, t_i, p_i),$$

où (x_i, y_i) localise le pixel, t_i indique l'instant du changement et $p_i \in \{-1, +1\}$ sa polarité, selon qu'il s'agit d'une diminution ou d'une augmentation de luminosité. Le capteur n'enregistre donc ni couleur ni image complète, mais un nuage de changements dans l'espace (x, y, t) . La partie gauche de la **Figure 2** montre une trajectoire continue ; la partie droite illustre une scène urbaine, où les événements se concentrent sur les contours et les objets en mouvement tandis que les zones immobiles restent presque vides.




FIGURE 2 : Flux d'événements dans l'espace (x, y, t) .

Source : *AImageLab*

Un réseau convolutionnel ne pouvant pas traiter directement une liste de longueur variable, l'une des méthodes les plus couramment utilisées consiste à discrétiser le flux en intervalles temporels réguliers. C'est cette approche qui est retenue ici : le flux est découpé en T intervalles, puis les événements sont accumulés sur une grille et séparés par polarité, d'où un tenseur $[T, 2, H, W]$ compatible avec ce type de réseau (Gallego et al., 2022). Cette discrétisation introduit un compromis important pour la suite : des intervalles trop courts produisent des trames très parcimonieuses ; trop longs, ils mélangent des événements éloignés et effacent une partie de leur ordre.

2.2 Familles de modèles pour le traitement temporel

Trois familles principales traitent cette dimension temporelle.

Réseaux convolutionnels sans état. Chaque trame est traitée indépendamment par un réseau convolutionnel, puis les scores obtenus aux différents instants sont moyennés. Cette famille bénéficie des architectures classiques de vision, mais son défaut est structurel : la moyenne étant symétrique, la sortie reste inchangée lorsque les trames sont permutées. Le modèle peut reconnaître ce que contient la séquence, jamais dans quel ordre. Cette propriété en fait le contrôle sans mémoire utilisé plus loin.

Réseaux récurrents. Une cellule LSTM (Hochreiter et Schmidhuber, 1997) ou GRU entretient explicitement un vecteur d'état transmis d'un instant au suivant. La mémoire constitue ici un module identifié

et entraîné pour lui-même, ce qui en fait une référence pour les séquences, au prix de paramètres et d'un entraînement supplémentaires. Les architectures à attention (Vaswani et al., 2017) apprennent les dépendances globalement plutôt que pas à pas, avec un coût quadratique en longueur de séquence.

Réseaux de neurones impulsionnels. Le potentiel de membrane intègre les entrées passées et persiste entre les instants : la mémoire appartient à l'unité de calcul elle-même, sans cellule récurrente ajoutée. Les communications par impulsions binaires correspondent en outre à la nature du signal produit par le capteur. En contrepartie, la décharge non différentiable impose l'entraînement spécifique décrit à la Section 2.4. Le choix d'un SNN repose donc ici sur une hypothèse précise, qui sera testée expérimentalement : son état interne doit apporter une information que le contrôle sans mémoire ne peut pas reconstruire.

2.3 Le neurone impulsif

La Figure 3 montre les spikes entrants, l'accumulation du potentiel $V_i(t)$, puis le spike de sortie émis au franchissement de V_{th} , avant réinitialisation.




FIGURE 3 : Fonctionnement d'un neurone impulsif.

Source : Paredes-Vallés et al.

Le neurone IF, pour *Integrate-and-Fire*, formalise cette logique par

$$V_i(t) = V_i(t-1) + \sum_j w_{ij} s_j(t), \quad s_i(t) = \Theta(V_i(t) - V_{th}), \quad (1)$$

où w_{ij} est le poids synaptique et Θ la fonction de Heaviside. Le potentiel reste constant entre deux impulsions.

Le LIF (*Leaky Integrate-and-Fire*) utilisé ici (Gerstner et al., 2014) ajoute une fuite faisant décroître le potentiel entre deux impulsions. Les entrées récentes pèsent ainsi davantage que les anciennes : le neurone possède une mémoire dynamique de l'activité passée, contrairement au modèle IF dont le potentiel reste constant.

Après un spike, le reset soustractif $V_i \leftarrow V_i - V_{th}$ conserve la partie du potentiel située au-dessus du seuil, tandis que le reset à zéro l'efface entièrement. Les modèles étudiés emploient le premier, sans période réfractaire explicite. Les états internes sont réinitialisés entre deux séquences indépendantes afin d'éviter qu'une prédiction ne dépende de l'échantillon précédent.

2.4 Entraînement des réseaux impulsif

La fonction de décharge Θ n'étant pas différentiable, sa dérivée est nulle presque partout et bloque une rétropropagation classique. Le gradient de substitution (Neftci et al., 2019) conserve donc la décharge exacte pendant la passe avant, mais emploie la dérivée d'une fonction régulière pendant la passe arrière. Le réseau est déroulé sur T instants et entraîné par rétropropagation à travers le temps (Werbos, 1990). Le

graphe de calcul doit alors conserver les activations de chaque instant : la mémoire croît avec T et la taille du lot, d'où les petits lots indiqués en [Annexe A](#). Les modèles ont été développés avec PyTorch ([Paszke et al., 2019](#)) et SpikingJelly ([Fang et al., 2023](#)), puis entraînés sur les GPU du laboratoire.

2.5 Positionnement par rapport aux travaux existants

Les premiers SNN événementiels ont surtout traité des tâches où le temps sert de support : flot optique ([Cuadrado et al., 2023](#)) ou profondeur ([Rançon et al., 2022](#)), dont le signal utile est local et où la mémoire densifie une observation parcimonieuse. En reconnaissance, DVS-Gesture ([Amir et al., 2017](#)) est devenu une référence sur laquelle les architectures résiduelles impulsioneuses atteignent de hauts scores ([Fang et al., 2021](#)). Chaque séquence n'y contient toutefois qu'un geste, reconnaissable par les zones activées ou l'apparence agrégée sans que la chronologie soit nécessaire.

DVS-Gesture-Chain ([Vicente-Sola et al., 2025](#)) lève cette ambiguïté en concaténant plusieurs gestes et en définissant la classe par leur ordre complet. Deux chaînes contenant les mêmes gestes dans un ordre différent appartiennent alors à deux classes distinctes : la chronologie devient nécessaire à la solution. Ce stage en reprend le principe, puis le prolonge au [Chapitre 4](#) sur des activités du corps entier avec séparation stricte par participant. Cette dernière condition, absente du protocole initial, mesure la généralisation à des personnes dont la morphologie et la manière de bouger sont inconnues, plutôt que la reconnaissance d'identités déjà rencontrées.

Ce positionnement conduit à distinguer deux difficultés souvent confondues. La première est perceptive : reconnaître les activités présentes malgré leur variabilité visuelle. La seconde est temporelle : reconstruire leur ordre alors que leur contenu global est identique. Le chaînage rend la seconde mesurable ; la séparation par participant vérifie que le résultat ne repose pas sur des caractéristiques propres aux personnes vues pendant l'apprentissage. Les deux campagnes expérimentales reprennent cette distinction : DVS-GC contrôle la difficulté des primitives, puis MAD teste son maintien sur des mouvements du corps entier et des sujets inconnus.

2.6 Règles d'évaluation

Les trois ensembles ont des rôles distincts : les paramètres sont appris sur l'entraînement ; le checkpoint et les hyperparamètres sont choisis sur la validation ; le test n'est consulté qu'après gel de ces décisions. Cette règle évite de transformer le test en second ensemble de réglage. Sur MAD, le découpage se fait en outre par participant : aucune personne du test n'apparaît dans l'apprentissage, afin qu'une identité déjà vue ne facilite pas la mesure de généralisation.

La même discipline s'applique aux statistiques de normalisation : lorsqu'elles sont recalibrées avant l'évaluation, elles le sont uniquement à partir de l'ensemble d'entraînement. Chaque score doit enfin être rattaché à son protocole exact concernant les primitives, la longueur de chaîne, le nombre de trames, la partition et la taille de l'ensemble évalué. Cette précaution est indispensable dans la suite, car certains contrôles ne sont disponibles que sur un sous-ensemble du test et ne peuvent donc pas être comparés comme s'ils partageaient exactement les mêmes échantillons.

Perception de l'ordre temporel

Ce chapitre installe le dispositif expérimental du stage dans un cadre contrôlé. Le jeu de données, le protocole de chaînage et les modèles comparés sont d'abord décrits. La campagne commence ensuite par la reproduction du protocole de référence, puis étudie séparément l'effet de la difficulté visuelle, de la résolution temporelle et du mécanisme interne du réseau. Cette progression permet de valider la chaîne de calcul avant d'interpréter ses résultats.

3.1 Le jeu de données et sa préparation

DVS-Gesture (Amir et al., 2017) regroupe onze gestes des bras et des mains enregistrés par une caméra événementielle de résolution 128×128 . Chaque enregistrement est un flux (x, y, t, p) , converti selon la Section 2.1 en T trames à deux canaux de polarité. La tâche usuelle consiste à classer un geste isolé. Elle mesure la reconnaissance du geste dans son ensemble, mais ne permet pas de savoir si le modèle exploite l'ordre de ses phases : les zones activées ou l'apparence agrégée peuvent suffire. Le protocole suivant est précisément construit pour lever cette ambiguïté.

3.2 Le protocole de chaînage

DVS-Gesture-Chain (DVS-GC) (Vicente-Sola et al., 2025) concatène L gestes et définit la classe par leur ordre : (A, B, C) et (B, A, C) deviennent distinctes malgré un contenu identique. Leur séparation exige donc qu'une information sur les gestes précédents soit conservée. La chaîne compte T trames, mais la durée attribuée à chaque geste varie d'un échantillon à l'autre afin d'empêcher toute association simple entre une primitive et une position temporelle fixe. La Figure 4 résume le passage des événements au geste, puis du geste au tenseur d'entrée. Un exemple complet figure en Annexe C ; les frontières, ajoutées pour la lecture, ne sont pas fournies au modèle. Trois paramètres décrivent une configuration : le choix des primitives fixe la difficulté visuelle, la longueur L donne 3^L classes et le nombre de trames T fixe la résolution temporelle. Les expériences les font varier de façon contrôlée.




FIGURE 4 : Construction d'une chaîne DVS-GC, depuis les événements jusqu'à l'entrée temporelle du réseau.

3.3 Dispositif expérimental

3.3.1 Architecture S-ResNet-38

Dans un réseau résiduel, un bloc apprend une correction $F(x)$ ajoutée à son entrée, soit $y = F(x) + x$, plutôt qu’une transformation complète. La connexion directe facilite la circulation du gradient dans les réseaux profonds (He et al., 2016). S-ResNet (Vicente-Sola et al., 2022) conserve les convolutions et les connexions résiduelles, mais remplace les activations conventionnelles par des neurones LIF. La variante de 38 couches utilisée dans le protocole DVS-GC (Vicente-Sola et al., 2025) est présentée en Figure 5.

Dans l’implémentation du stage, une convolution d’entrée précède trois étages de six blocs, avec 32, 64 puis 128 canaux et une résolution spatiale décroissante. Les mêmes poids sont appliqués aux T trames, tandis que les potentiels de membrane des LIF évoluent d’un instant au suivant et transmettent ainsi une information sur l’activité passée. Après un pooling global, une couche linéaire produit un vecteur de scores à chaque instant ; la décision de séquence en prend la moyenne :

$$s(x_{1:T}) = \frac{1}{T} \sum_{t=1}^T s_t.$$

Conserver l’architecture de référence permet d’évaluer la reproduction sans modifier simultanément tâche et modèle.




FIGURE 5 : Architecture S-ResNet-38 employée dans les expériences.

3.3.2 Normalisation temporelle

Une normalisation par lot classique utilise une moyenne et une variance communes (Ioffe et Szegedy, 2015). Dans un SNN, cette hypothèse est fragile : les potentiels et les spikes produits précédemment modifient l’état courant, si bien que la distribution des activations évolue au cours de la séquence. Les premiers instants peuvent être presque silencieux alors que l’activité est installée aux derniers.

BNTT (*Batch Normalization Through Time*) (Kim et Panda, 2021) attribue donc à chaque instant ses propres statistiques et paramètres de mise à l’échelle, tout en partageant les poids convolutionnels. La mémoire reste portée par les neurones LIF ; BNTT ne crée pas une récurrence supplémentaire, mais calibre séparément les activations rencontrées à chaque instant (Figure 6). Cette dépendance à t devra néanmoins être contrôlée, car elle peut elle-même révéler la position temporelle.

3.3.3 Modèles comparés

Trois variantes partagent le même squelette convolutionnel. Le modèle de référence emploie des LIF à fuite et reset soustractif : une partie du potentiel subsiste après la décharge. Le deuxième utilise des IF sans fuite avec reset à zéro : il conserve un état, mais l’efface entièrement après chaque spike. Le troisième remplace les neurones par des ReLU et BNTT par une normalisation classique. Il traite les trames indépendamment puis moyenne leurs scores ; sa sortie est donc invariante à toute permutation. Ce contrôle fournit la borne expérimentale de ce qui est accessible sans mémoire de l’ordre.




FIGURE 6 : Principe de BNTT : les poids convolutionnels sont partagés entre les instants, tandis que chaque pas de temps possède ses propres statistiques et paramètres de normalisation.

3.4 Reproduction du protocole de référence

La campagne commence par la reproduction du protocole de référence, afin de valider l'implémentation avant de modifier simultanément la difficulté ou le modèle. Elle utilise les primitives 1, 3 et 8, respectivement *Right Hand Wave*, *Right Arm Clockwise* et *Air Drums*, des chaînes $L = 4$ (81 classes) sur $T = 60$ trames. S-ResNet-38 atteint 97,48 % au test, contre $95,83 \pm 0,62$ % dans l'article (Vicente-Sola et al., 2025). Les valeurs sont cohérentes, sans comparaison stricte car primitives et tirage des durées peuvent différer. La chaîne de calcul est donc cohérente. Ce score élevé rend toutefois l'étude de la mémoire peu discriminante : les sections suivantes durcissent la tâche avant d'interpréter le rôle du temps.

3.5 Effet du recouvrement spatial et de la résolution temporelle

La configuration suivante utilise les primitives 0, 7 et 8, soit *Hand Clapping*, *Arm Roll* et *Air Drums*. Ces trois gestes activent des régions proches autour du corps et des bras. Les chaînes sont ramenées à $L = 3$ (27 classes) afin de ne pas confondre ce recouvrement spatial avec la difficulté qu'introduirait une chaîne plus longue. Deux résolutions temporelles sont comparées sur cette configuration : $T = 40$ donne 71,07 % en validation, $T = 60$ atteint 76,79 %. Une description plus fine aide donc à distinguer les gestes, mais répartit le même flux sur davantage d'instant : chaque trame devient plus parcimonieuse et les statistiques de BNTT plus sensibles au contenu des lots (Figure 17, Annexe C). Le recalcul des statistiques sur l'ensemble d'entraînement avant chaque évaluation réduit cette dépendance et porte la validation à 81,96 %. La suite retient donc 0/7/8, $L = 3$, $T = 60$ et cette calibration.

3.6 Rôle du mécanisme temporel

Les trois modèles de la Section 3.3.3 sont entraînés dans les mêmes conditions (Tableau 1).

TABEAU 1 : Influence du mécanisme temporel sur DVS-GC 0/7/8, $L = 3$, $T = 60$, à conditions identiques. Exactitudes de validation.

Modèle	Validation	Information temporelle
ANN, ReLU et BN	34,64 %	aucune mémoire entre les trames
SNN, IF et reset à zéro	72,50 %	potentiel entièrement réinitialisé
SNN, LIF et reset soustractif	81,96 %	état résiduel conservé

BNTT associe des paramètres distincts à chaque instant et encode ainsi implicitement la position temporelle.

Un contrôle ReLU qui la conserve atteint 98,57 %, sans aucune dynamique interne : son score ne prouve donc pas qu’il perçoit l’ordre par mémoire. La normalisation classique partagée supprime cette fuite et rend le contrôle réellement invariant à la permutation.

Ce contrôle obtient 34,64 %, une valeur proche de la borne théorique de 37,0 % pour un système qui reconnaît les trois gestes présents mais ignore leurs permutations. Son comportement correspond donc bien au rôle qui lui est assigné. L’IF améliore nettement le score, et le LIF à reset soustractif atteint 81,96 %. L’article observe l’ordre inverse entre ces deux neurones sur une autre configuration : le mécanisme le plus favorable dépend donc de la tâche, et non d’une supériorité absolue du LIF.

Enfin, les exactitudes par position valent 86,07 %, 84,46 % et 82,68 %. Leur diminution reste modérée lorsque l’état accumule les gestes précédents : la mémoire devient légèrement plus difficile à exploiter, mais ne s’effondre pas au long de la chaîne.

3.7 Bilan de la campagne DVS-GC

Trois résultats sont établis. S-ResNet-38 reproduit la référence ; des primitives spatialement proches rendent la tâche plus discriminante ; une résolution fine aide mais rend BNTT plus sensible aux lots. Surtout, supprimer l’état interne est la modification la plus pénalisante lorsque le contrôle ne dispose d’aucun autre indice de position. Le chapitre suivant reprend architecture, LIF, chaînage et calibration sur des activités du corps entier, avec des participants inconnus du modèle, tout en réexaminant T et la normalisation.

Reconnaissance d'activités sur MAD

Ce chapitre transpose le dispositif contrôlé du chapitre précédent à des activités quotidiennes du corps entier, enregistrées auprès d'une centaine de participants. Les personnes sont strictement séparées entre apprentissage, validation et test. Le raisonnement conserve la même charpente : données, protocole, dispositif, diagnostic et contrôles, afin d'identifier précisément ce qui se maintient et ce qui doit être adapté lors du changement d'échelle.

4.1 Le jeu de données et sa préparation

MAD, constitué à ETIS (Béranger et al., 2025), synchronise radar, capture du mouvement et caméra événementielle ; seule cette dernière modalité est utilisée pendant le stage. Cent participants réalisent neuf activités : marcher, se lever, s'asseoir, monter ou descendre des marches, ramasser un objet, enjamber un obstacle, effectuer un demi-tour et chuter (Figure 7). Ces catégories n'occupent ni la même région ni la même durée : la marche produit une silhouette étendue, tandis que la chute déplace rapidement l'activité vers le bas du champ. Chaque fichier CSV contient (x, y, p, t) à 640×480 sur dix secondes, alors que le mouvement utile n'en occupe qu'une partie. Le prétraitement calcule la densité d'événements par intervalles de 50 ms, puis conserve la fenêtre de trois secondes dont la densité cumulée est maximale. La carte d'occupation de [Annexe C](#) montre que l'activité utile se concentre au centre de l'image ; elle justifie le recadrage $x \in [120, 520]$, $y \in [80, 440]$, ensuite redimensionné à 128×128 . L'opération élimine des pixels presque inactifs et réduit le coût sans retirer la zone parcourue par les participants. Les événements sont enfin accumulés dans T trames à deux polarités. Le cache est indexé par les paramètres de fenêtre, de recadrage et de résolution, afin d'être reconstruit dès que l'un d'eux change.




FIGURE 7 : Vue d'ensemble des neuf activités de MAD dans la modalité événementielle. Le rouge et le bleu correspondent aux deux polarités.

4.2 Le protocole MAD-Chain

Le chaînage de la [Section 3.2](#) est repris sans en modifier le principe. Les primitives sont marcher, s’asseoir et chuter, disponibles pour l’ensemble des participants et caractérisées par des dynamiques distinctes. Des clips réellement acquis sont concaténés en chaînes $L = 3$ (27 classes) sur $T = 40$ trames, avec une durée variable par activité ([Figure 8](#)).

La différence décisive avec DVS-GC est le découpage : les participants 1-70, 71-85 et 86-100 forment respectivement apprentissage, validation et test, soit 1 890, 1 215 et 1 215 chaînes sans personne partagée. Le modèle est donc évalué sur des morphologies et des manières de bouger qu’il n’a jamais observées.




FIGURE 8 : Exemples de chaînes MAD-Chain. Chaque ligne montre une succession différente de gestes.

4.3 Dispositif expérimental

S-ResNet-38, les LIF à reset soustractif, la calibration avant évaluation et le contrôle ReLU sont conservés. Deux éléments changent : la résolution passe à $T = 40$, choix qui sera vérifié parmi les leviers du diagnostic, et la normalisation devient elle-même un objet d’étude lorsque BNTT se révèle instable sur ces données plus variées.

4.4 Diagnostic de l’instabilité en validation

La configuration héritée atteint 78,44 % au test : elle établit que l’ordre est perçu sur des activités réelles et des sujets inconnus. La validation oscille cependant de plusieurs dizaines de points alors que l’apprentissage progresse régulièrement. Le problème porte donc d’abord sur la fiabilité de la mesure : un tel signal ne permet ni de choisir un checkpoint ni de comparer proprement deux variantes.

Trois familles de causes sont testées en ne modifiant qu’une variable à la fois : la procédure d’apprentissage (moyennage des poids, recuit cosinus), la représentation ($T = 50$ ou 30) et les données (miroir horizontal). Les six essais de [Tableau 7](#), en [Annexe B](#), ne suppriment pas l’instabilité. Le moyennage la masque dans un modèle final lissé mais dégrade le test ; $T = 50$ l’aggrave en raréfiant encore les activations par instant. Ces résultats confirment le choix de $T = 40$.

Le raisonnement par élimination devient alors informatif : les poids évoluent régulièrement, l’ensemble évalué reste fixe et les trois axes précédents ont été écartés. La source restante est BNTT, dont chaque module temporel estime ses statistiques sur seulement B activations parcimonieuses. L’instabilité n’est donc pas un simple défaut de réglage ; la correction doit viser la normalisation elle-même.

4.5 Normalisation conjointe

BNTT estime chaque instant sur les B éléments du lot. tdbN (*Threshold-Dependent Batch Normalization*) (Zheng et al., 2021) mutualise au contraire le lot et les T instants :

$$\mu = \frac{1}{TB} \sum_{t=1}^T \sum_{b=1}^B x_{t,b}, \quad \sigma^2 = \frac{1}{TB} \sum_{t=1}^T \sum_{b=1}^B (x_{t,b} - \mu)^2.$$

La valeur normalisée est mise à l'échelle par le seuil V_{th} :

$$\hat{x} = \alpha V_{th} \frac{x - \mu}{\sqrt{\sigma^2 + \varepsilon}}, \quad y = \gamma \hat{x} + \beta.$$

La mutualisation augmente l'échantillon utilisé pour estimer moyenne et variance, tout en supprimant les modules séparés par instant (Figure 9). Elle répond directement au diagnostic précédent : les statistiques reposent désormais sur $T \times B$ valeurs plutôt que sur les seuls B éléments associés à un instant.




FIGURE 9 : Comparaison des domaines utilisés pour estimer les statistiques de BNTT et de tdbN.

Cette modification impose en contrepartie de traiter toute la séquence dans chaque bloc, composé d'une convolution, d'une normalisation conjointe puis de l'évolution des LIF, avec une mémoire proportionnelle à $T \times B$. Le meilleur checkpoint atteint 97,94 % en validation et 97,12 % au test (Tableau 2).

TABLEAU 2 : Résultats principaux de MAD-Chain pour $L = 3$, $T = 40$ et 27 classes. Le hasard vaut 3,7 % et la borne d'un modèle invariant à la permutation 37,0 %. Les deux contrôles à normalisation conjointe (ANN-tdBN et GRU) sont évalués sur un sous-ensemble de 405 chaînes de test (cf. Annexe A).

Modèle	Normalisation	Validation	Test
ANN sans mémoire	BN	$\approx 15\%$ ^a	8,81 %
ANN sans mémoire	tdBN	36,2 %	31,85 % ^c
SNN	BNTT	instable ^b	78,44 %
SNN	tdBN	97,94 %	97,12 %
GRU récurrent	sans objet	non suivi	99,93 % ^d

^a L'ANN plafonne à $\approx 40\%$ même en apprentissage : incapacité structurelle, non surapprentissage.

^b Validation oscillant de plusieurs dizaines de points d'une époque à l'autre : aucune valeur unique n'est représentative.

^c Normalisation identique au SNN, seul le neurone change.

^d Encodeur convolutionnel suivi d'un GRU, architecture distincte de S-ResNet-38.

La Figure 10 montre que tdbN remplace la validation irrégulière de BNTT par une progression continue et un plateau stable : niveau et sélection du checkpoint s'améliorent ensemble.

Lecture des contrôles

L'ANN avec BN n'atteint que 8,81 %. La moyenne temporelle lisse les phases brèves qui distinguent notamment une chute d'une assise, tandis que la normalisation classique généralise mal lorsque la morphologie change. Son écart au SNN additionne donc deux effets et ne permet pas, seul, d'isoler la mémoire.

Le contrôle ANN-tdBN lève cette ambiguïté : la normalisation est identique à celle du SNN et seuls les LIF sont remplacés par des ReLU. Il obtient 31,85 % sur 405 chaînes, proche de la borne de permutation 37,0 %. Le SNN atteint 97,12 % sur 1 215 chaînes. Les ensembles différents interdisent une comparaison chiffrée strictement appariée, mais le plafonnement de l'ANN à l'entraînement fournit une indication forte du rôle de la dynamique temporelle.

Enfin, un encodeur convolutionnel suivi d'un GRU atteint 99,93 % sur les mêmes 405 chaînes : la tâche est bien résoluble lorsqu'une mémoire est présente. Le léger écart avec le SNN ne doit pas être surinterprété puisque l'encodeur diffère. L'intérêt propre du SNN réside dans son mode de calcul événementiel et parcimonieux, qui réduit le nombre d'activations et favorise une meilleure efficacité énergétique.




FIGURE 10 : Évolution de l'exactitude de validation sur MAD-Chain avec BNTT et tdBN.

4.6 Robustesse du protocole

La matrice de confusion de [Annexe B](#) montre que les erreurs ne sont pas uniformes : certaines assises ou chutes sont classées comme de la marche. Cette structure oriente vers le prétraitement, car la fenêtre de densité maximale peut inclure l'approche pendant laquelle le participant marche réellement. Une fenêtre tardive, centrée sur la fin du clip, est donc testée pour vérifier si un cadrage plus proche de l'activité corrige ces confusions. La fenêtre tardive n'atteint que 84,36 % en validation : la fin d'une assise ou d'une chute correspond souvent à une personne immobile et produit peu d'événements. L'essai écarte donc une correction simple par déplacement et confirme que la fenêtre dense conserve le segment le plus informatif.

La seconde vérification allonge les chaînes à $L = 4$ (81 classes), avec tdBN et $T = 40$. Après convergence, la validation vaut 97,04 % et le test 96,93 %. Les positions atteignent 99,73 %, 98,96 %, 98,90 % et 98,68 % ; leur produit (96,3 %) reste proche du score complet. Les erreurs sont donc rares et beaucoup moins corrélées qu'au chapitre précédent.

4.7 Bilan de la campagne MAD

Trois résultats sont établis. La configuration héritée transfère à des activités réelles et à des sujets inconnus. L'instabilité est attribuée à BNTT après élimination des causes liées à l'apprentissage, à la représentation et aux données ; tdBN la résout et porte le test de 78,44 % à 97,12 %. Ce niveau se maintient lorsque le nombre de classes passe de 27 à 81. Les scores DVS-GC et MAD ne sont toutefois pas directement comparables : le premier sépare des gestes spatialement proches, le second ordonne des activités distinctes sur des personnes inconnues.

Étude préliminaire de la détection de chute

Les deux campagnes précédentes ont établi que la dynamique interne du réseau porte une information d'ordre sur des activités réelles et des participants inconnus. Ce chapitre passe de cette question scientifique à un premier usage : détecter un événement critique et le situer dans le temps. La formulation « une séquence, une classe » est remplacée par une décision à chaque instant. La configuration validée est conservée ; seule la lecture de sortie change, afin que les effets observés puissent être attribués à cette nouvelle tâche.

5.1 Le protocole de détection

Le prétraitement de la [Section 4.1](#) est conservé, mais le vocabulaire passe de trois à l'ensemble des neuf activités de MAD. Les chaînes comportent cinq activités sur $T = 50$ trames afin de garder une résolution comparable par activité. Environ la moitié contient une chute unique, à une position quelconque ; les autres ne contiennent que des activités ordinaires. Prédire systématiquement l'absence de chute donnerait donc environ 50 % d'exactitude sans détecter le moindre événement. L'exactitude de séquence n'est pas une mesure recevable à elle seule, d'où les métriques adaptées définies plus bas.

5.2 Dispositif expérimental

S-ResNet-38, les LIF à reset soustractif, tBN et la séparation par participant sont conservés. La couche de sortie n'est plus moyennée : elle est lue à chaque instant sous la forme $[B, T, 9]$, avec une étiquette d'activité par trame. La chute étant brève et minoritaire à cette échelle, sa classe est pondérée dans l'entropie croisée.

Une séquence est déclarée positive si au moins K trames sont prédites comme des chutes ([Figure 11](#)). Ce seuil constitue un véritable point de fonctionnement : une valeur faible transforme une erreur isolée en fausse alerte, tandis qu'une valeur trop élevée manque les chutes les plus brèves. La position des trames positives fournit en outre la localisation temporelle de l'événement. L'évaluation combine sensibilité, précision, F1, taux de fausses alarmes et exactitude par trame. La sensibilité mesure la proportion de chutes détectées ; les fausses alarmes portent uniquement sur les séquences sans chute ; le F1 combine rappel et précision. Manquer une chute étant plus grave qu'une alerte injustifiée, sensibilité et fausses alarmes doivent être lues conjointement.




FIGURE 11 : Prédiction par trame et règle de décision : une chute est déclarée lorsqu'au moins K trames sont classées comme telles.

5.3 Pondération de la classe rare et point de fonctionnement

Deux réglages conditionnent le résultat : le poids attribué à la chute pendant l'entraînement et le seuil K appliqué aux prédictions. Un poids trop faible fait ignorer la classe rare ; trop élevé, il fait apparaître des chutes partout. Avec $T = 40$ et un poids 4, rappel et fausses alarmes avoisinent 1 et le F1 vaut 0,81, ce qui rend le modèle inutilisable. Un poids 2 à $T = 50$ réduit fortement les alertes sans dégrader le rappel (F1 0,876).

La troisième configuration ne change ni le modèle ni les données : elle consigne plusieurs seuils à chaque époque et sélectionne le checkpoint sur le F1 de détection plutôt que sur l'exactitude par trame. Ce seul changement porte le F1 à 0,939, montrant que le critère de sélection importe autant que l'entraînement lorsque la métrique applicative diffère de la fonction optimisée. Chaque époque coûte environ 76 minutes avec un lot de trois séquences. Le **Tableau 3** détaille les cinq valeurs de K en validation.

TABLEAU 3 : Détection en validation selon K , configuration v3.

K	Sensibilité	Précision	F1	Fausse alarmes
1	1,000	0,695	0,820	0,468
2	0,996	0,816	0,897	0,239
3	0,987	0,895	0,939	0,124
4	0,935	0,939	0,937	0,064
5	0,858	0,961	0,907	0,037

Le seuil K est sélectionné uniquement sur l'ensemble de validation. Le modèle et ce seuil sont ensuite évalués sur l'ensemble de test, sans nouvel ajustement. Cet ensemble contient 450 séquences, dont 232 avec une chute. L'exactitude par trame y vaut 70,92 %.

TABLEAU 4 : Détection au test selon K : 450 séquences, dont 232 chutes.

K	Sensibilité	Précision	F1	Fausse alarmes
1	0,996	0,724	0,838	0,404
2	0,996	0,837	0,909	0,206
3	0,991	0,902	0,945	0,115
4	0,957	0,937	0,947	0,069
5	0,892	0,963	0,926	0,037

La **Figure 12** présente un coude net à $K = 3$: en dessous, les fausses alarmes croissent rapidement pour un gain minime de sensibilité ; au-dessus, la sensibilité diminue sans réduction comparable des alertes. Le seuil retenu correspond donc au compromis mesuré sur la validation, et non à une valeur choisie arbitrairement.




FIGURE 12 : Compromis entre sensibilité et fausses alarmes selon le seuil K sur l'ensemble de validation. Le point retenu est entouré.

Choisi sur la validation, $K = 3$ y donne 98,7 % de sensibilité et 12,4 % de fausses alarmes. Sans ajustement au test, il atteint 99,1 %, 90,2 % de précision, un F1 de 0,945 et 11,5 % de fausses alarmes. Le F1 test de $K = 4$ est légèrement supérieur (0,947), mais ne justifie pas un choix a posteriori.

Dans la Figure 13, l'exactitude par trame progresse régulièrement de 0,19 à 0,74, ce qui indique un apprentissage sain, mais le F1 oscille. Quelques trames autour du seuil suffisent en effet à faire basculer la décision de toute une séquence : une variation mineure à l'échelle de la trame devient importante après agrégation.




FIGURE 13 : Exactitude par trame et score F1 de détection au seuil $K = 3$, au fil des époques.

5.4 Bilan de l'étude

La lecture par trame permet à la fois de détecter et de localiser la chute. La pondération, le critère de sélection du checkpoint et le seuil documentent le compromis au lieu de le masquer dans une exactitude globale. Sélectionnés sur la validation puis figés, le checkpoint et $K = 3$ généralisent aux 450 chaînes de test avec une sensibilité de 99,1 %, une précision de 90,2 %, un F1 de 0,945 et 11,5 % de fausses alarmes.

Le contrôle sans mémoire des chapitres précédents n'est plus adapté, mais pour une raison instructive. La difficulté ne porte plus sur l'ordre entre plusieurs activités : elle porte sur la signature temporelle interne d'une chute, rapide, par opposition au mouvement plus lent et contrôlé d'une assise ou d'un ramassage. Un modèle temporel de capacité comparable, par exemple une tête récurrente, serait ici le contrôle pertinent.

Synthèse et conclusion

6.1 Réponse à la problématique

Ce rapport répond à la question suivante : la dynamique temporelle interne d'un réseau de neurones impulsionnels est-elle effectivement exploitée pour percevoir l'ordre d'activités décrites par un flux événementiel, et cet apport se maintient-il lorsque l'on passe de gestes contrôlés à des activités réelles réalisées par des personnes inconnues du modèle ? La réponse est positive, mais elle dépend de la validité du dispositif de comparaison.

Sur DVS-GC, le contrôle ReLU avec normalisation classique atteint 34,64 %, une valeur proche de la borne théorique de 37,0 % d'un modèle capable de reconnaître les gestes sans pouvoir les ordonner, tandis que le SNN-LIF atteint 81,96 %. L'état interne fournit donc une information utile lorsque l'ordre est nécessaire. Cette campagne a toutefois révélé que BNTT pouvait elle-même encoder la position temporelle par ses paramètres propres à chaque instant. Un réseau sans dynamique qui conserve BNTT atteint ainsi 98,57 %. Cette configuration ne permet donc pas d'attribuer le résultat à la mémoire du réseau et impose la construction d'un contrôle réellement aveugle à l'ordre.

La campagne MAD apporte la réponse dans ce cadre corrigé. Avec tdbN, dont les statistiques sont partagées sur toute la séquence, le contrôle sans mémoire redevient invariant à la permutation. Il atteint 31,85 % sur 405 chaînes de test, près de la borne théorique de 37,0 %, et plafonne autour de 40 % à l'apprentissage. Le SNN atteint pour sa part 97,12 % sur l'ensemble complet de 1 215 chaînes.

Les deux modèles n'ayant pas été évalués sur exactement le même nombre de chaînes, leurs scores ne constituent pas une comparaison strictement appariée. Les différents contrôles montrent néanmoins que l'absence de dynamique temporelle, plutôt qu'un défaut de normalisation, limite le modèle sans mémoire. Un GRU résout également la tâche, ce qui confirme que la dynamique temporelle est nécessaire sans être exclusivement impulsionnelle. Le SNN conserve toutefois un avantage propre : son calcul événementiel et parcimonieux réduit les opérations actives et place le gain d'efficacité énergétique de son côté.

Les deux campagnes jouent ainsi des rôles complémentaires. DVS-GC a validé le dispositif expérimental et établi les conditions d'une comparaison interprétable. MAD fournit la démonstration principale sur des activités du corps entier et sur des participants jamais observés pendant l'apprentissage.

6.2 Bilan du travail réalisé

Le travail a associé lecture d'articles, reconstruction d'architectures, prétraitement de données, entraînement sur serveur GPU et analyse détaillée des erreurs. Cette analyse n'a pas servi qu'à constater : chaque diagnostic a été réinvesti dans une version plus robuste du dispositif. Il a également fallu adapter des méthodes publiées à des cas d'usage pour lesquels elles n'avaient pas été conçues.

La campagne DVS-GC a d'abord servi de cadre contrôlé. Elle a validé la réimplémentation de S-ResNet-38, puis séparé les variantes de neurone sur des primitives dont les zones de spikes se chevauchent. Elle a aussi permis de distinguer la difficulté perceptive, liée à la proximité spatiale des gestes, de la difficulté temporelle, liée à leur ordre, et de vérifier l'effet de la résolution des trames sur le comportement du réseau.

La campagne MAD a porté le protocole de chaînage, défini sur des gestes de bras exécutés face à la caméra,

à des activités du corps entier avec séparation stricte par participant. Elle a fait apparaître un problème que la seule lecture des scores aurait masqué : une validation trop instable pour désigner un checkpoint de manière fiable. Le remplacement de BNTT par une normalisation conjointe a levé cette instabilité et fait progresser nettement l'exactitude de test. Le gain se maintient lorsque les chaînes s'allongent à quatre activités, ce qui confirme la robustesse du protocole au-delà de sa première configuration.

L'étude préliminaire de détection de chute prolonge enfin ce dispositif vers un usage de surveillance. La même architecture y est reformulée en lecture par trame, ce qui permet à la fois de détecter l'événement et de le localiser. Le travail a aussi porté sur la pondération de la classe rare, le choix du checkpoint selon le score F1 et la définition d'un point de fonctionnement qui documente explicitement le compromis entre sensibilité et fausses alarmes, plutôt que de le fixer d'avance.

6.3 Apports méthodologiques

Le premier apport méthodologique est d'avoir séparé le rôle des expériences. La reproduction valide l'implémentation, le changement de primitives augmente l'ambiguïté spatiale, les variantes de neurones étudient la réinitialisation et les essais sur MAD éliminent plusieurs causes avant d'agir sur la normalisation. Chaque expérience répond ainsi à une question précise, sans variation simultanée de plusieurs facteurs.

Le deuxième apport est d'avoir montré qu'un contrôle peut être invalidé par un composant supposé neutre. Comparer le réseau impulsionnel à un réseau sans mémoire n'est pertinent que si ce dernier est réellement aveugle à l'ordre, ce que la normalisation par pas de temps empêchait sans que les courbes le révèlent. Le contraste entre les deux versions du contrôle quantifie ce mécanisme et attribue à tdbn un rôle essentiel : au-delà de la stabilité, elle rend la comparaison interprétable.

Le troisième apport concerne l'instabilité observée sur MAD. Au lieu de retenir le meilleur point d'une courbe bruitée, elle a été traitée comme un problème de mesure puis attribuée, par élimination, à la normalisation. Ce passage de la performance à la fiabilité de la mesure a permis d'obtenir un gain réel plutôt qu'apparent.

Ces apports convergent vers la détection de chute, étudiée dans le dernier chapitre. Cette tâche n'avait pas encore été abordée sur ces données. Elle exigeait un dispositif dont le comportement soit compris, un contrôle réellement aveugle à l'ordre et une procédure de sélection fiable. L'ensemble construit au fil des deux campagnes rend ainsi recevable la formulation en détection : une lecture par trame localise l'événement, tandis qu'un point de fonctionnement est choisi explicitement.

6.4 Compétences mobilisées et acquises

Sur le plan technique, la prise en main de PyTorch a consolidé mes connaissances en apprentissage profond et en architectures de réseaux, tout en m'ouvrant à l'intelligence artificielle bio-inspirée à travers les réseaux de neurones impulsionnels.

Le stage m'a surtout apporté une méthodologie de recherche : lire les travaux existants avec un regard critique, reproduire un protocole de référence pour en vérifier la validité, puis l'adapter à un cas d'usage précis. Cette démarche m'a appris à ne pas considérer une mesure comme acquise, à rechercher l'origine d'un comportement avant de le corriger et à distinguer ce qu'un résultat établit de l'interprétation qu'on lui attribue.

Le stage a également renforcé mes compétences logicielles. J'ai développé et exécuté toute la chaîne expérimentale sous Linux sur serveur : sessions distantes, gestion des environnements et des entraînements, suivi de l'exécution et contrôle de leur bon déroulement. J'ai aussi appris à adapter les entraînements aux ressources disponibles et à en optimiser l'usage en tenant compte du coût de calcul des modèles.

6.5 Perspectives

Le prolongement le plus naturel de ce travail est le passage de chaînes contrôlées à des flux continus. Les séquences étudiées ici sont construites par concaténation. Le nombre d'activités est fixé, mais la durée variable des gestes rend leurs frontières temporelles inconnues du modèle. Leur enchaînement reste néanmoins artificiel, puisqu'il résulte de la juxtaposition de segments distincts. En situation réelle, le système reçoit un flux ininterrompu dans lequel un nombre variable d'activités s'enchaîne selon des transitions naturelles et où un événement critique doit être repéré au moment où il survient. La surveillance à domicile en est l'exemple type : une chute doit être détectée au fil de l'activité quotidienne. L'étude menée ici constitue une première étape, puisqu'elle remplace la classification d'une séquence entière par une lecture par trame. Son prolongement consiste à appliquer cette approche à des flux continus aux transitions naturelles et à exploiter les neuf activités de MAD plutôt que les trois retenues dans l'étude préliminaire. Cette perspective concerne aussi la navigation autonome, où une caméra événementielle observe une scène continue et des usagers qui entrent ou sortent du champ à des instants imprévisibles.

L'évaluation doit également dépasser la classe attribuée à une séquence. Elle doit mesurer la reconnaissance de chaque activité, sa localisation temporelle et la robustesse face à des activités absentes de l'apprentissage, inévitables dans un flux ouvert. Pour un véhicule autonome, détecter un piéton ne suffit pas : il faut le localiser lorsqu'il surgit et rester fiable face à des situations inédites afin de prévenir une collision.

C'est dans ce cadre que le SNN prend toute sa valeur. Compétitif en exactitude face à un modèle récurrent, il conserve l'avantage d'un calcul événementiel et parcimonieux, qui réduit les opérations actives et favorise une faible consommation. Pour une surveillance permanente ou une perception embarquée soumise à des contraintes énergétiques, le gain d'efficacité se situe du côté du SNN et constitue un argument décisif pour la détection continue d'événements critiques.

- AImageLab (s. d.). *Video Synthesis from Intensity and Event Frames*. Università di Modena e Reggio Emilia. <https://aimagelab-legacy.ing.unimore.it/imagelab/researchActivity.asp?idActivity=055>.
- Amir, A., Taba, B., Berg, D. J., Melano, T., McKinstry, J. L., Nolfo, C. di, Nayak, T. K. et al. (2017). “A Low Power, Fully Event-Based Gesture Recognition System”. In : *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, p. 7388-7397. doi : [10.1109/CVPR.2017.781](https://doi.org/10.1109/CVPR.2017.781).
- Béranger, C., Bordat, A., Acin, L., Dobias, P., Simon Chane, C., Vu, N.-S., Le Kernec, J., Guyard, D., Histace, A. et Romain, O. (2025). “Multimodal Activity Dataset (MAD)”. In : Manuscrit en préparation, laboratoire ETIS, UMR 8051 CY Cergy Paris Université / ENSEA / CNRS.
- Cuadrado, J., Rançon, U., Cottureau, B. R., Barranco, F. et Masquelier, T. (2023). “Optical flow estimation from event-based cameras and spiking neural networks”. In : *Frontiers in Neuroscience* 17, p. 1160034. doi : [10.3389/fnins.2023.1160034](https://doi.org/10.3389/fnins.2023.1160034).
- Fang, W., Chen, Y., Ding, J., Yu, Z., Masquelier, T., Chen, D., Huang, L., Zhou, H., Li, G. et Tian, Y. (2023). “SpikingJelly : An open-source machine learning infrastructure platform for spike-based intelligence”. In : *Science Advances* 9.40, eadi1480. doi : [10.1126/sciadv.adi1480](https://doi.org/10.1126/sciadv.adi1480).
- Fang, W., Yu, Z., Chen, Y., Huang, T., Masquelier, T. et Tian, Y. (2021). “Deep Residual Learning in Spiking Neural Networks”. In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 34, p. 21056-21069.
- Gallego, G., Delbrück, T., Orchard, G., Bartolozzi, C., Taba, B., Censi, A., Leutenegger, S., Davison, A. J., Conradt, J., Daniilidis, K. et Scaramuzza, D. (2022). “Event-Based Vision : A Survey”. In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* 44.1, p. 154-180. doi : [10.1109/TPAMI.2020.3008413](https://doi.org/10.1109/TPAMI.2020.3008413).
- Gehrig, M., Aarents, W., Gehrig, D. et Scaramuzza, D. (2021). “DSEC : A Stereo Event Camera Dataset for Driving Scenarios”. In : *IEEE Robotics and Automation Letters* 6.3, p. 4947-4954. doi : [10.1109/LRA.2021.3068942](https://doi.org/10.1109/LRA.2021.3068942).
- Gerstner, W., Kistler, W. M., Naud, R. et Paninski, L. (2014). *Neuronal Dynamics : From Single Neurons to Networks and Models of Cognition*. Cambridge University Press. ISBN : 978-1107635197. doi : [10.1017/CB09781107447615](https://doi.org/10.1017/CB09781107447615).
- He, K., Zhang, X., Ren, S. et Sun, J. (2016). “Deep Residual Learning for Image Recognition”. In : *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, p. 770-778. doi : [10.1109/CVPR.2016.90](https://doi.org/10.1109/CVPR.2016.90).
- Hochreiter, S. et Schmidhuber, J. (1997). “Long Short-Term Memory”. In : *Neural Computation* 9.8, p. 1735-1780. doi : [10.1162/neco.1997.9.8.1735](https://doi.org/10.1162/neco.1997.9.8.1735).
- Ioffe, S. et Szegedy, C. (2015). “Batch Normalization : Accelerating Deep Network Training by Reducing Internal Covariate Shift”. In : *Proceedings of the 32nd International Conference on Machine Learning*. T. 37. Proceedings of Machine Learning Research. PMLR, p. 448-456.
- Kim, Y. et Panda, P. (2021). “Optimizing Deeper Spiking Neural Networks for Dynamic Vision Sensing”. In : *Neural Networks* 144, p. 686-698. doi : [10.1016/j.neunet.2021.09.022](https://doi.org/10.1016/j.neunet.2021.09.022).

- Neftci, E. O., Mostafa, H. et Zenke, F. (2019). “Surrogate Gradient Learning in Spiking Neural Networks : Bringing the Power of Gradient-Based Optimization to Spiking Neural Networks”. In : *IEEE Signal Processing Magazine* 36.6, p. 51-63. doi : [10.1109/MSP.2019.2931595](https://doi.org/10.1109/MSP.2019.2931595).
- Paredes-Vallés, F., Scheper, K. Y. W. et Croon, G. C. H. E. de (2020). “Unsupervised Learning of a Hierarchical Spiking Neural Network for Optical Flow Estimation : From Events to Global Motion Perception”. In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* 42.8, p. 2051-2064. doi : [10.1109/TPAMI.2019.2903179](https://doi.org/10.1109/TPAMI.2019.2903179).
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L. et al. (2019). “PyTorch : An Imperative Style, High-Performance Deep Learning Library”. In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 32, p. 8024-8035.
- Rançon, U., Cuadrado-Anibarro, J., Cottureau, B. R. et Masquelier, T. (2022). “StereoSpike : Depth Learning With a Spiking Neural Network”. In : *IEEE Access* 10, p. 127428-127439. doi : [10.1109/ACCESS.2022.3226484](https://doi.org/10.1109/ACCESS.2022.3226484).
- Ronneberger, O., Fischer, P. et Brox, T. (2015). “U-Net : Convolutional Networks for Biomedical Image Segmentation”. In : *Medical Image Computing and Computer-Assisted Intervention : MICCAI 2015*. T. 9351. Lecture Notes in Computer Science. Springer, p. 234-241. doi : [10.1007/978-3-319-24574-4_28](https://doi.org/10.1007/978-3-319-24574-4_28).
- Santé publique France (12 mars 2026). *Hospitalisations et mortalité en lien avec une chute chez les personnes de 65 ans et plus en France. Données 2015-2024*. <https://invs.santepubliquefrance.fr/traumatismes/chute/bulletin-national/hospitalisations-et-mortalite-en-lien-avec-une-chute-chez-les-personnes-de-65-ans-et-plus-en-france>.
- Shidling, C. (18 oct. 2025). *Normal Camera Vs Event-Based Camera : Understanding the Future of Vision Systems*. <https://www.cselectricalandelectronics.com/normal-camera-vs-event-based-camera-understanding-the-future-of-vision-systems/>.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł. et Polosukhin, I. (2017). “Attention Is All You Need”. In : *Advances in Neural Information Processing Systems*. T. 30, p. 5998-6008.
- Vicente-Sola, A., Manna, D. L., Kirkland, P., Di Caterina, G. et Bihl, T. J. (2022). “Keys to Accurate Feature Extraction Using Residual Spiking Neural Networks”. In : *Neuromorphic Computing and Engineering* 2.4, p. 044001. doi : [10.1088/2634-4386/ac8bef](https://doi.org/10.1088/2634-4386/ac8bef).
- Vicente-Sola, A., Manna, D. L., Kirkland, P., Di Caterina, G. et Bihl, T. J. (2025). “Spiking Neural Networks for event-based action recognition : A new task to understand their advantage”. In : *Neurocomputing* 611, p. 128657. doi : [10.1016/j.neucom.2024.128657](https://doi.org/10.1016/j.neucom.2024.128657).
- Wang, X., Ellul, J. et Azzopardi, G. (2020). “Elderly Fall Detection Systems : A Literature Survey”. In : *Frontiers in Robotics and AI* 7, p. 71. doi : [10.3389/frobt.2020.00071](https://doi.org/10.3389/frobt.2020.00071).
- Werbos, P. J. (1990). “Backpropagation Through Time : What It Does and How to Do It”. In : *Proceedings of the IEEE* 78.10, p. 1550-1560. doi : [10.1109/5.58337](https://doi.org/10.1109/5.58337).
- Zheng, H., Wu, Y., Deng, L., Hu, Y. et Li, G. (2021). “Going Deeper With Directly-Trained Larger Spiking Neural Networks”. In : *AAAI Conference on Artificial Intelligence*. T. 35. 12, p. 11062-11070. doi : [10.1609/aaai.v35i12.17320](https://doi.org/10.1609/aaai.v35i12.17320).

Hyperparamètres et effectifs

Les configurations rapportées dans le corps du texte partagent la même procédure d’entraînement. Les deux tableaux de cette annexe en rassemblent les paramètres, afin que chaque résultat puisse être rattaché au protocole exact qui l’a produit.

Les effectifs de MAD-Chain pour $L = 3$ sont de 1 890 chaînes d’apprentissage, 1 215 de validation et 1 215 de test, construites respectivement à partir des participants 1 à 70, 71 à 85 et 86 à 100. Le contrôle récurrent et le contrôle sans mémoire à normalisation conjointe ont été évalués sur un sous-ensemble de 405 chaînes de test tiré des mêmes participants 86 à 100, ce dont la lecture de leurs exactitudes tient compte.

Trois précisions méritent d’être signalées. La taille de lot n’est pas un choix de réglage mais une contrainte : la rétropropagation à travers le temps conserve les activations des T instants, si bien que l’empreinte mémoire croît comme $T \times B$. Certaines variantes ont donc été entraînées avec un lot plus petit que la configuration de référence. Le contrôle sans mémoire, ensuite, est obtenu en construisant le modèle impulsif puis en remplaçant ses neurones par des ReLU, les convolutions et la normalisation restant inchangées : la normalisation est ainsi strictement identique à celle du modèle qu’il sert à contrôler, ce qui garantit que la comparaison ne fait varier que le mécanisme temporel.

TABLEAU 5 : Paramètres des modèles construits sur S-ResNet-38 : réseau impulsionnel et contrôles sans mémoire. Seul le neurone distingue le contrôle du modèle de référence à normalisation donnée.

Paramètre	DVS-GC	MAD-Chain
Architecture	S-ResNet-38	S-ResNet-38
Canaux par étage	32 / 64 / 128	32 / 64 / 128
Blocs par étage	6	6
Neurone	LIF, reset soustractif	LIF, reset soustractif
Contrôle sans mémoire	ReLU (37 neurones remplacés)	ReLU (mêmes couches)
Gradient de substitution	sigmoïde ($\alpha = 4,0$)	sigmoïde ($\alpha = 4,0$)
Seuil V_{th}	1,0	1,0
Normalisation	BN et BNTT	BN, BNTT puis tdbN
Readout	moyenne des scores sur T	moyenne des scores sur T
Optimiseur	AdamW	AdamW
Pas d'apprentissage	10^{-4}	10^{-4}
Décroissance des poids	10^{-2}	10^{-2}
Ordonnancement du pas	constant	constant
Taille de lot B	8	4
Nombre d'époques	50	60
Graine aléatoire	unique, non variée	unique, non variée
Résolution T	40 puis 60	40 ; 50 pour la détection
Longueur L	4 puis 3	3 puis 4 ; 5 pour la détection
Nombre de classes	81 puis 27	27 puis 81
Coût par époque	≈ 271 s (contrôle ANN)	≈ 36 min

TABLEAU 6 : Paramètres du contrôle récurrent. Son encodeur convolutionnel diffère de S-ResNet-38, ce dont la discussion des résultats tient compte.

Paramètre	DVS-GC	MAD-Chain
Encodeur	4 blocs Conv-BN-ReLU, 32 / 64 / 128 / 128, pooling adaptatif	
Sortie de l'encodeur	vecteur de 128 composantes par trame	
Cellule récurrente	GRU, 2 couches, 256 unités cachées	
Régularisation	dropout 0,3	
Classifieur	couche linéaire sur le dernier état caché	
Optimiseur	AdamW	AdamW
Pas d'apprentissage	10^{-4}	10^{-4}
Décroissance des poids	10^{-2}	10^{-2}
Écrêtage du gradient	1,0	1,0
Taille de lot B	8	16
Nombre d'époques	50	60
Résolution T	60	40
Coût par époque	≈ 60 s	≈ 55 s

Analyses complémentaires

Cette annexe rassemble les analyses qui appuient le corps du texte sans être nécessaires à sa lecture.

Matrices de confusion

La **Figure 14** donne la matrice de confusion de la configuration DVS-GC 0/7/8 ($L = 3$, $T = 60$), agrégée par primitive. La confusion dominante oppose *Arm Roll* à *Air Drums*, deux gestes de bras dont les zones d'activité se recouvrent : elle confirme que le plafond de performance provient de la proximité visuelle des primitives, conformément au choix de configuration de la **Section 3.5**.

La **Figure 15** donne la matrice de confusion sur MAD-Chain, agrégée par activité. Les erreurs ne sont pas réparties uniformément : certaines séquences d'assise ou de chute sont classées comme de la marche. Cette asymétrie oriente vers une cause située dans le prétraitement plutôt que dans le modèle, et motive l'essai de fenêtre tardive discuté à la **Section 4.6**.




FIGURE 14 : Matrice de confusion par primitive sur DVS-GC 0/7/8 ($L = 3$, $T = 60$). Les valeurs sont des effectifs ; les lignes correspondent à la vérité, les colonnes à la prédiction.




FIGURE 15 : Matrice de confusion par activité sur MAD-Chain ($L = 3, T = 40$). Les lignes correspondent à la vérité, les colonnes à la prédiction.

Infrastructure expérimentale

Les entraînements ont été menés sur deux serveurs GPU partagés du laboratoire, équipés de cartes Quadro RTX 8000 disposant de 46 Go de mémoire.

Un entraînement complet de 60 époques demande entre trente et quarante heures selon la configuration. Pour la tâche de détection de chute, à $T = 50$ et avec un lot de trois séquences, une époque demande à elle seule environ 76 minutes.

Les données prétraitées sont mises en cache et identifiées par les paramètres de fenêtre temporelle, de recadrage spatial et de résolution : toute modification du prétraitement entraîne donc automatiquement la reconstruction du cache, ce qui évite qu'un résultat soit obtenu sur des données ne correspondant plus à la configuration déclarée. Les courbes d'apprentissage et de validation ont été suivies à l'aide d'un service de journalisation d'expériences, et chaque exécution conserve son journal, ses checkpoints et la configuration qui l'a produite.

Données et représentations




FIGURE 16 : Exemple de chaîne DVS-GC construite avec les primitives de la première combinaison. Les limites entre gestes ne sont pas fournies au modèle : elles ne sont indiquées ici que pour la lisibilité.




FIGURE 17 : Influence de T sur la densité des trames : une résolution temporelle plus fine produit des activations plus parcimonieuses.

Configurations successives de l'étude de détection de chute

Le [Tableau 8](#) détaille les trois configurations résumées à la [Section 5.3](#). Chacune ne modifie qu'une variable par rapport à la précédente.




FIGURE 18 : Occupation spatiale des événements MAD dans la résolution native 640×480 . Les bandes périphériques ne produisent pratiquement aucun spike, ce qui justifie le recadrage retenu à la [Section 4.1](#).




FIGURE 19 : Exactitude par position pour la variante DVS-GC 0/7/8 à $T = 60$.

TABLEAU 7 : Leviers testés contre l’instabilité de la validation sur MAD-Chain, avec BNTT. La colonne « meilleure validation » donne le meilleur point atteint, et la colonne « amplitude » l’écart maximal observé entre deux époques consécutives une fois l’apprentissage engagé.

Levier	Axe visé	Meilleure val.	Ampli.	Lecture
Référence (BNTT)	référence	0,79	$\approx 0,6$	instabilité constatée, point de départ du diagnostic
Moyennage des poids	procédure d’apprentissage	0,85	≈ 0	fournit un modèle final stable (poids moyennés), mais sans gain, et dégrade le test
Recuit cosinus du pas	procédure d’apprentissage	$\approx 0,78$	$\approx 0,6$	l’oscillation persiste : le pas d’apprentissage n’est pas en cause
$T = 50$	représentation	0,90	$\approx 0,8$	oscillation aggravée, sans amélioration du niveau
$T = 30$	représentation	$\approx 0,70$	$\approx 0,5$	trames plus denses, mais résolution temporelle insuffisante
Miroir horizontal	données	$\approx 0,79$	$\approx 0,6$	sans effet mesurable sur l’oscillation

TABLEAU 8 : Configurations successives de l’étude de détection.

Version	Configuration	Résultat
v1	$T = 40$, poids de chute 4	rappel proche de 1 mais fausses alarmes proches de 1 également, F1 plafonnant à 0,81
v2	$T = 50$, poids de chute 2	fausses alarmes fortement réduites à rappel constant, meilleur F1 0,876
v3	identique à v2, avec suivi des métriques pour $K = 1 \dots 5$ et sélection du checkpoint sur le F1	meilleur F1 0,939

Un travail exploratoire : estimation du flot optique

Les premières semaines du stage ont été consacrées à une prise en main de la vision événementielle par une tâche différente de celle qui occupe le corps de ce rapport : l'estimation du flot optique, à partir de l'article de [Cuadrado et al. \(2023\)](#). Il s'agissait de construire une chaîne complète, depuis les événements bruts jusqu'à une prédiction produite par un réseau impulsif, avant d'aborder la question de la dynamique temporelle. Cette annexe en rend compte brièvement.

Contrairement à la classification, la sortie attendue n'est pas une classe mais un vecteur de mouvement pour chaque pixel, $\hat{\mathbf{F}}(x, y) = (\hat{u}, \hat{v})$. Le modèle réimplémenté est une architecture de type U-Net ([Ronneberger et al., 2015](#)) adaptée aux données événementielles : son encodeur traite conjointement l'espace et le temps par des convolutions tridimensionnelles, dont le noyau temporel réduit progressivement la séquence de vingt-et-une tranches à une seule, tandis que le décodeur, entièrement bidimensionnel, reconstruit une carte de flot dense. Les prédictions intermédiaires de chaque niveau sont accumulées dans un neurone dont le seuil est fixé à l'infini : ne déchargeant jamais, son potentiel de membrane sert de registre à la prédiction cumulative. La version réimplémentée compte environ 1,22 million de paramètres.

Le modèle a été entraîné sur les séquences de conduite du jeu DSEC ([Gehrig et al., 2021](#)). Un script de prétraitement autonome a été développé pour lire les fichiers HDF5 et les annotations, associer les événements aux intervalles temporels du flot de référence, rectifier leurs coordonnées et construire les tenseurs spatio-temporels à deux canaux de polarité, ainsi que les masques de pixels valides. Ce prétraitement a produit 7 334 paires d'entraînement et 818 paires de validation. La supervision combine un terme sur la norme de l'erreur et un terme sur sa direction, et n'est appliquée qu'aux pixels que les annotations déclarent valides.

L'entraînement a fait apparaître une contrainte que le reste du stage retrouvera : à cette résolution, l'empreinte mémoire est dominée non par les paramètres du modèle, pourtant peu nombreux, mais par les activations conservées à tous les instants pour la rétropropagation à travers le temps. Une taille de lot de quatre suffisait à saturer une carte de 46 Go.

La perte de validation a décliné régulièrement au fil des époques et les prédictions reproduisent la structure d'ensemble du mouvement, comme le montre la [Figure 21](#). Le périmètre de cette étude reste celui d'une prise en main : les découpages, la durée des fenêtres temporelles et les hyperparamètres diffèrent de ceux du protocole publié, de sorte que les valeurs obtenues ne sont pas directement comparables aux siennes.

L'apport de ces premières semaines tient au dispositif qu'elles ont mis en place. La construction de tenseurs spatio-temporels à partir d'un flux asynchrone, la manipulation des neurones impulsifs et de leur état interne, l'apprentissage par gradients de substitution et la conduite d'entraînements longs sur des serveurs partagés y ont été maîtrisés, puis directement réinvestis dans les campagnes présentées aux chapitres qui précèdent.




FIGURE 20 : Architecture U-Net impulsioneuse réimplémentée pour l'estimation dense du flot optique. L'encodeur tridimensionnel intègre le contexte temporel, que le décodeur bidimensionnel reconstruit ensuite à la résolution d'entrée.

Source : *Cuadrado et al.*




FIGURE 21 : Exemples de prédictions sur le jeu de validation, du mieux estimé au plus difficile. De gauche à droite : projection des événements, flot de référence, flot prédit et carte d'erreur. Les cas difficiles correspondent aux régions de faible densité événementielle et aux frontières séparant deux mouvements distincts.